R2-A1-S10 Redes Neuronales V

Bryan Felipe Roa Alvarado

Nidia Stella García Roa

Universidad de Cundinamarca

Facultad de Ingeniería, Esp. en Inteligencia Artificial

Fusagasugá

2026

Tabla de contenido

1. Introducción 6

1.1 Contexto 6

1.2 Alcance 6

2. Marco teórico 7

2.1 Redes Neuronales Siamesas 7

2.2 Embeddings faciales 7

2.3 Triplet Loss 7

2.4 One-shot, Few-shot y Zero-shot Learning 8

2.5 Preprocesamiento de imágenes faciales 8

3. Metodología 10

3.1 Entorno de ejecución 10

3.2 Dataset sintético 11

3.3 Arquitectura del encoder 11

3.4 Generación de tripletas 12

3.5 Entrenamiento 13

4. Resultados 14

4.1 Dataset sintético y consideraciones éticas 14

4.2 Tripleta Anchor-Positive-Negative 14

4.3 Arquitectura y forma del embedding 15

4.4 Curva de Triplet Loss 16

4.5 Distancias medias positivas y negativas 17

4.6 Histograma de distancias 17

4.7 One-shot Learning 18

4.8 Few-shot Learning 18

4.9 Umbral pedagógico y verificaciones 19

5. Discusión 20

5.1 Naturaleza métrica del aprendizaje 20

5.2 Por qué el experimento NO demuestra Zero-shot real 20

5.3 Limitaciones del experimento 20

5.4 Extensión a imágenes reales autorizadas 21

6. Conclusiones 22

7. Anexos 23

7.1 Preguntas de cierre resueltas 23

8. GitHub 24

Resumen

La presente práctica implementó una red neuronal siamesa con Triplet Loss en PyTorch, ejecutada en Google Colab, con el objetivo de aprender una representación vectorial (embedding) de rostros sintéticos que permita comparar similitud entre identidades. Se entrenó un encoder convolucional de 64 dimensiones sobre 4 identidades × 12 variantes (48 imágenes 64×64) con una TripletMarginLoss de margen 0.8 y un optimizador Adam. Tras 18 épocas la pérdida descendió de 0.3981 a valores próximos a 0.0; la distancia media positiva fue 0.1312 frente a 1.5421 de las negativas, con una clara separación en el histograma (relación ≈ 11.75×). Los clasificadores One-shot (1 referencia por identidad) y Few-shot (3 referencias con prototipo promedio normalizado) alcanzaron accuracy de 1.0 (44/44 y 36/36). El umbral pedagógico de verificación se situó en 0.8367, verificando correctamente un par de la misma identidad (distancia 0.2070 → MISMA) y un par de identidades diferentes (distancia 1.2789 → DIFERENTE). Se concluye que la práctica ilustra el aprendizaje métrico y las estrategias One-shot/Few-shot, y se aclara explícitamente que **no constituye una demostración de Zero-shot real**, porque las identidades evaluadas participaron en el entrenamiento del extractor.

Conceptos clave:

- Redes Neuronales Siamesas (SNN)
- Embeddings faciales
- Triplet Loss
- One-shot Learning
- Few-shot Learning
- Zero-shot Learning (discusión conceptual)
- Preprocesamiento de imágenes faciales
- Aprendizaje métrico (metric learning)

1. Introducción

1.1 Contexto

El reconocimiento facial moderno basado en Deep Learning ha migrado del paradigma de clasificación tradicional (una neurona de salida por identidad) hacia el paradigma del aprendizaje métrico: una red aprende a proyectar cada rostro en un espacio vectorial donde las distancias reflejan similitud de identidad. Este enfoque, popularizado por arquitecturas como FaceNet (Schroff et al., 2015), permite comparar rostros mediante distancias y extiende su aplicabilidad a escenarios en los que las identidades no fueron vistas durante el entrenamiento (One-shot, Few-shot, Zero-shot).

Las Redes Neuronales Siamesas (SNN), introducidas por Bromley, Bentz, Bottou, Guyon, LeCun, Moore, Säckinger y Shah en 1994 y popularizadas por Koch, Zemel y Salakhutdinov (2015) para reconocimiento One-shot, constituyen la arquitectura natural para este paradigma. La presente práctica implementa una SNN con Triplet Loss en PyTorch, dentro del marco de la semana 10 de la asignatura Redes Neuronales V.

1.2 Alcance

La práctica se ejecuta sobre un dataset sintético de 48 rostros (4 identidades × 12 variantes), generado programáticamente sin emplear datos biométricos reales. Se entrena una SNN con Triplet Loss, se evalúa su desempeño mediante One-shot y Few-shot Learning, se construye un umbral pedagógico de verificación y se discute por qué el experimento no constituye una demostración de Zero-shot real. Se documenta, además, la extensión a imágenes reales autorizadas.

2. Marco teórico

2.1 Redes Neuronales Siamesas

Una Red Neuronal Siamesa (SNN) es una arquitectura compuesta por dos o más ramas idénticas que **comparten pesos**. Cada rama es un extractor de características (encoder) que proyecta una entrada en un vector compacto llamado embedding. La red no clasifica directamente: aprende una función de similitud que acerca embeddings de la misma identidad y aleja los de identidades distintas. Su utilidad radica en que la comparación puede hacerse con una o pocas referencias por identidad, sin necesidad de reentrenar el modelo cuando aparecen clases nuevas.

2.2 Embeddings faciales

Un embedding facial es un vector numérico compacto (en esta práctica, 64 dimensiones) que resume las características relevantes de una imagen de rostro para la tarea de comparación. Una buena representación hace que embeddings de la misma persona queden próximos (baja distancia) y embeddings de personas distintas queden alejados (alta distancia). La calidad del embedding depende críticamente del preprocesamiento y de la diversidad del dataset de entrenamiento.

2.3 Triplet Loss

Triplet Loss es una función de pérdida que opera sobre tripletas (a, p, n): un **anchor** (ancla), un **positive** (misma identidad que el anchor) y un **negative** (identidad distinta). Su objetivo es acercar la distancia anchor-positive y alejar la distancia anchor-negative en al menos un margen α. Formalmente:

$$L(a, p, n) = \max(||f(a) - f(p)||^2 - ||f(a) - f(n)||^2 + \alpha , 0)$$

Donde f es la función que implementa el encoder, ||·|| es la norma euclidiana (L2) y α es el margen. Un margen mayor exige una separación más estricta entre las

distancias; un margen nulo permite que la red colapse hacia soluciones triviales. En esta práctica se usó α = 0.8.

2.4 One-shot, Few-shot y Zero-shot Learning

One-shot Learning:

Reconocimiento o comparación de una identidad a partir de **una sola** imagen de referencia. Es el escenario natural de la verificación facial en control de acceso o pasaportes.

Few-shot Learning:

Uso de **k referencias** (típicamente 2–5) por identidad. Una estrategia habitual es construir un **prototipo** (promedio normalizado de los embeddings de referencia) y comparar contra él, lo que reduce la sensibilidad a una captura particular (iluminación, pose, ruido).

Zero-shot Learning:

Reconocimiento de identidades **no vistas durante el entrenamiento del extractor**. Requiere mecanismos adicionales (atributos semánticos, descripciones en lenguaje natural, o un modelo generativo) que permitan inferir la identidad a partir de información auxiliar. Esta práctica NO demuestra Zero-shot real y se explica en la sección 5.2.

2.5 Preprocesamiento de imágenes faciales

El preprocesamiento es una etapa crítica en cualquier sistema de reconocimiento facial. Sus pasos habituales son:

1. Detección del rostro (bounding box) mediante MTCNN, RetinaFace o Haar Cascades.

2. Recorte de la región facial.
3. Alineación (opcional) usando puntos faciales de referencia.
4. Redimensionamiento a un tamaño fijo (64×64 en esta práctica; 160×160 o 224×224 en sistemas reales).
5. Conversión a escala de grises o normalización de canales.
6. Normalización de píxeles al rango [0, 1] o [-1, 1].
7. Aumentación de datos (volteo horizontal, rotaciones leves, variaciones de brillo) para robustez.

3. Metodología

3.1 Entorno de ejecución

La práctica se desarrolló en Google Colab con Python 3 y PyTorch 2.11.0+cpu. Se seleccionó automáticamente CPU en la ejecución validada (no se activó GPU). Se fijó la semilla SEED = 42 para garantizar la reproducibilidad del experimento.

Tabla 1. Configuración experimental

Componente	Versión / Configuración
Entorno	Google Colab (Python 3)
Framework	PyTorch 2.11.0+cpu
Dispositivo	cpu
Semilla	42
Dataset	48 imágenes sintéticas 64×64 (grises)
Identidades	4 (12 variantes por identidad)
Épocas	18
Batch size	32
Learning rate	1e-3 (Adam)
Margen Triplet Loss	0.8

3.2 Dataset sintético

Se generaron programáticamente 48 rostros sintéticos mediante la función synthetic_face(identity, variant, size=64). Cada identidad se caracteriza por una combinación de rasgos (posición y tamaño de ojos, posición de la boca, presencia de accesorios como sombrero o gafas) que permanece estable entre variantes. Las variantes introducen pequeñas traslaciones y ruido gaussiano controlado, simulando condiciones reales de captura sin emplear datos biométricos.

Tabla 2. Identidades sintéticas

Identidad	Rasgo distintivo	Estilo
0	Cara sonriente estándar	0
1	Ceño fruncido con sombrero	1
2	Boca con elipse y ojos separados	2
3	Cara alargada con línea vertical	3

3.3 Arquitectura del encoder

El encoder es una red convolucional ligera que proyecta cada imagen 64×64 en un vector de 64 dimensiones, normalizado con L2 para que todas las comparaciones de distancia sean consistentes. La arquitectura se resume en la Tabla 3.

Tabla 3. Arquitectura del encoder convolucional

Capa	Configuración	Forma de salida
Conv2d	1→8, kernel 3, padding 1	[B, 8, 64, 64]
ReLU	—	[B, 8, 64, 64]
MaxPool2d	2	[B, 8, 32, 32]
Conv2d	8→16, kernel 3, padding 1	[B, 16, 32, 32]
ReLU	—	[B, 16, 32, 32]
MaxPool2d	2	[B, 16, 16, 16]
Conv2d	16→32, kernel 3, padding 1	[B, 32, 16, 16]
ReLU	—	[B, 32, 16, 16]
AdaptiveAvgPool2d	(4, 4)	[B, 32, 4, 4]
Flatten	—	[B, 512]
Linear	512→64	[B, 64]
Normalize L2	p=2, dim=1	[B, 64]

3.4 Generación de tripletas

La clase TripletFaces construye, en cada iteración, una tripleta (anchor, positive, negative) muestreando aleatoriamente una clase y seleccionando dos imágenes de esa

clase (anchor y positive) y una imagen de una clase distinta (negative). Se generaron 400 tripletas por época, entregadas en lotes de 32.

3.5 Entrenamiento

Se entrenó el modelo durante 18 épocas con TripletMarginLoss de margen 0.8 (norma L2) y optimizador Adam con tasa de aprendizaje 1e-3. La pérdida media por época se registró y se graficó para analizar la convergencia.

4. Resultados

4.1 Dataset sintético y consideraciones éticas

La Figura 1 muestra las 48 imágenes generadas (4 identidades × 12 variantes). Dentro de cada fila se conservan los rasgos estructurales de la identidad, mientras las columnas introducen pequeñas variaciones de posición y ruido, lo que permite entrenar y evaluar la red sin comprometer datos biométricos reales.

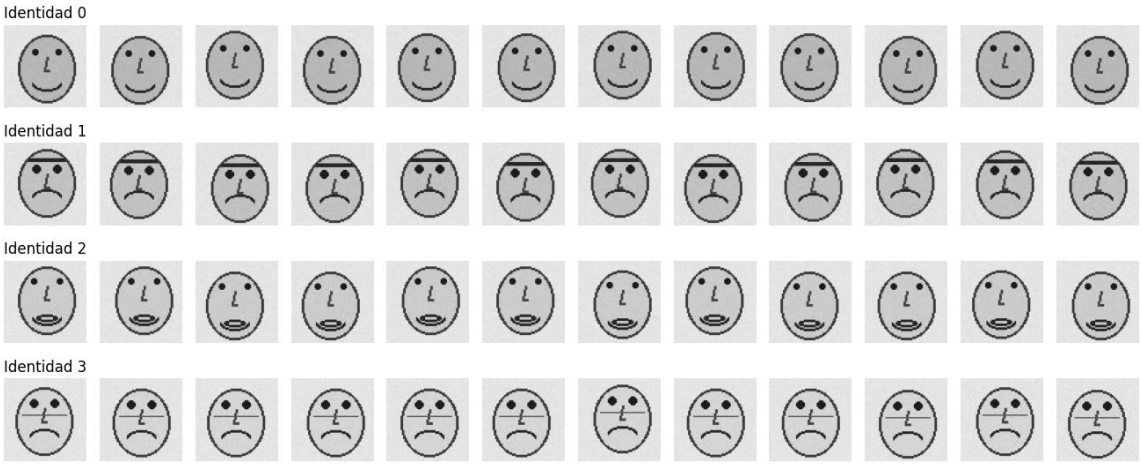


Figura 1. Dataset sintético: 4 identidades × 12 variantes. Cada fila conserva los rasgos de una identidad; cada columna introduce pequeñas variaciones de posición y ruido.

4.2 Tripleta Anchor-Positive-Negative

La Figura 2 muestra una tripleta de ejemplo generada por el Dataset. Anchor y Positive pertenecen a la misma identidad (clase 0); Negative pertenece a una identidad distinta (clase 1). Esta relación es la que la Triplet Loss utiliza para aprender el espacio métrico.

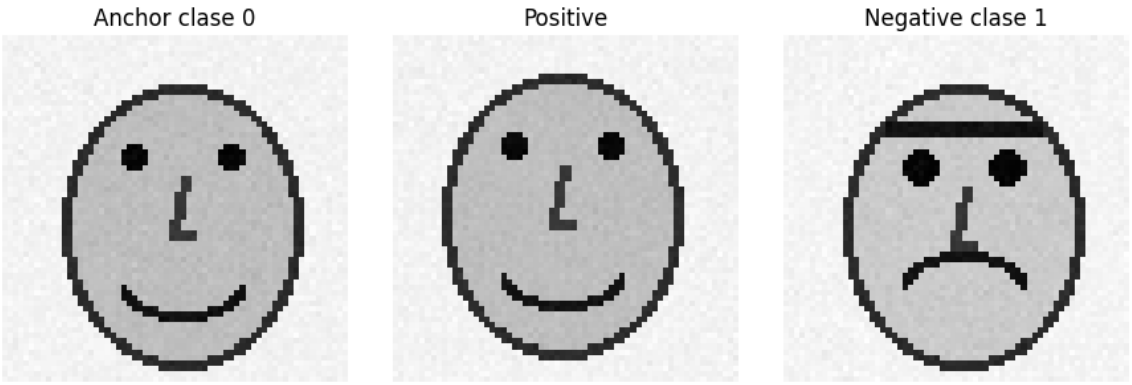


Figura 2. Ejemplo de tripleta Anchor-Positive-Negative. Anchor y Positive comparten identidad; Negative es de otra clase.

4.3 Arquitectura y forma del embedding

El encoder produce, para un lote de 32 imágenes, un tensor de forma [32, 64]. Cada embedding tiene norma L2 unitaria (verificado con float(emb[0].norm()) = 1.0 en la ejecución real), lo que garantiza que las distancias sean comparables entre pares. La Tabla 3 (sección 3.4) resume las capas. El rango de los píxeles normalizados de entrada fue [0.0784, 0.9451] tras dividir por 255.

Tabla 4. Propiedades del embedding

Propiedad	Valor
Dimensión del embedding	64
Forma de salida (batch 32)	[32, 64]
Norma L2 de cada embedding	1.0
Parámetros entrenables (aprox.)	~35 K
Rango de píxeles normalizados	[0.0784, 0.9451]

4.4 Curva de Triplet Loss

La Figura 3 muestra la evolución de la pérdida media por época. Se observa un descenso abrupto de 0.3981 en la primera época a 0.0266 en la segunda y 0.0024 en la tercera, con estabilización en 0.0000 hacia la época 6. Este comportamiento es típico de un dataset sintético sencillo y de una tarea separable; en datos reales la convergencia suele ser más lenta y ruidosa.

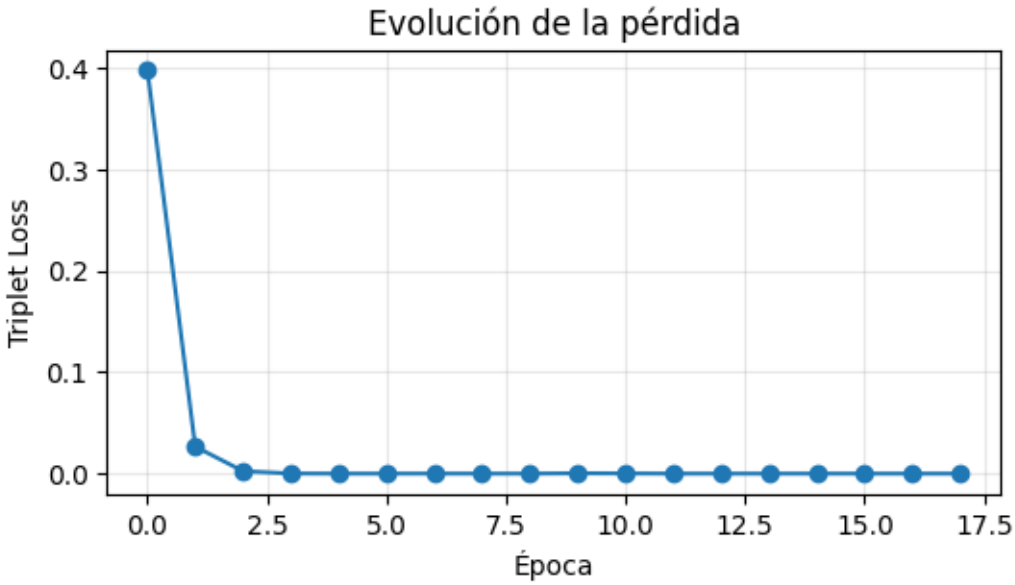


Figura 3. Evolución de Triplet Loss durante 18 épocas. El descenso abrupto es característico de un dataset sintético separable.

Tabla 5. Pérdida en épocas seleccionadas

Época	Loss
1	0.3981
2	0.0266
3	0.0024
6	0.0000

11	0.0002
18	0.0000

4.5 Distancias medias positivas y negativas

Sobre el conjunto completo de pares, se calculó la distancia euclidiana entre todos los pares de imágenes. La Tabla 6 resume los valores medios. La relación negativa/positiva es ≈ 11.75×, lo que confirma que el encoder aprendió a separar identidades con un margen amplio.

Tabla 6. Distancias medias y umbral pedagógico

Métrica	**Valor**
Distancia positiva media	0.1312
Distancia negativa media	1.5421
Relación negativa/positiva	≈ 11.75×
Umbral (mean_pos + mean_neg) / 2	0.8367

4.6 Histograma de distancias

La Figura 4 muestra el histograma de distancias. Se observa una clara separación bimodal: las distancias positivas se concentran cerca de 0.0–0.25 y las negativas se distribuyen entre 1.0 y 1.9. Esta separación es la evidencia visual de que el espacio de embeddings es discriminativo.

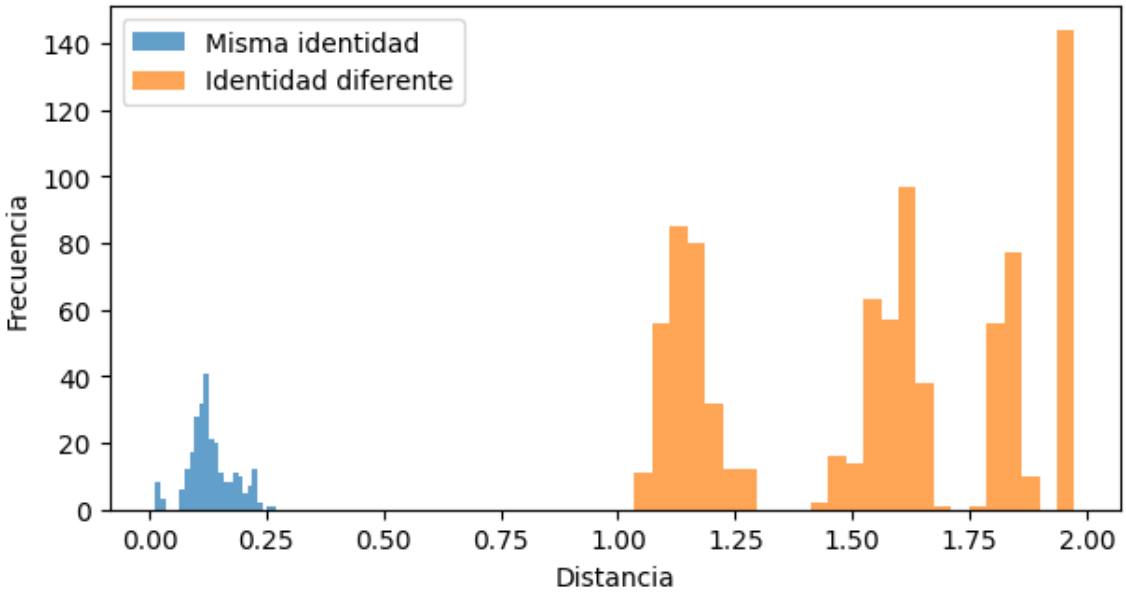


Figura 4. Histograma de distancias. Las distancias positivas (misma identidad) se concentran cerca de 0 y las negativas se distribuyen entre 1.0 y 1.9.

4.7 One-shot Learning

Para One-shot se reservó una imagen de referencia por identidad y se clasificaron las 44 imágenes restantes por vecino más cercano en el espacio de embeddings. La accuracy obtenida fue 1.0 (44/44). El resultado es consistente con la separación observada en el histograma: una sola referencia es suficiente para discriminar entre las cuatro identidades sintéticas.

4.8 Few-shot Learning

Para Few-shot se usaron 3 referencias por identidad, se calculó un prototipo (promedio normalizado) por identidad y se clasificaron las 36 imágenes restantes por distancia al prototipo más cercano. La accuracy obtenida fue 1.0 (36/36).

Tabla 7. Comparación One-shot vs. Few-shot

Estrategia	Referencias/identidad	Accuracy
One-shot	1	1.0 (44/44)
Few-shot	3 (prototipo promedio)	1.0 (36/36)

En este dataset sintético ambos enfoques alcanzan el 100%; en datos reales, Few-shot suele ser más robusto porque el prototipo reduce la sensibilidad a una captura particular (iluminación, pose, ruido).

4.9 Umbral pedagógico y verificaciones

Se definió un umbral pedagógico como el promedio de las distancias medias positiva y negativa: (0.1312 + 1.5421) / 2 = 0.8367. Se verificaron dos pares: uno de la misma identidad (distancia 0.2070 → MISMA) y uno de identidades diferentes (distancia 1.2789 → DIFERENTE). Ambos fueron clasificados correctamente.

Tabla 8. Verificaciones con umbral pedagógico

Par	Distancia	Umbral	Resultado
(0, 1) — misma identidad	0.2070	0.8367	MISMA
(0, 12) — distinta identidad	1.2789	0.8367	DIFERENTE

\

5. Discusión

5.1 Naturaleza métrica del aprendizaje

La red no aprendió a clasificar identidades: aprendió a organizar el espacio de embeddings de modo que las distancias reflejen similitud. Esta distinción es fundamental: permite comparar identidades nuevas mediante una o pocas referencias, sin redefinir la arquitectura ni agregar neuronas de salida. Es la base del reconocimiento facial moderno basado en embeddings.

5.2 Por qué el experimento NO demuestra Zero-shot real

El encoder fue entrenado con las cuatro identidades sintéticas que luego se usaron en las pruebas. Por tanto, todas las identidades de evaluación participaron en el entrenamiento y no son desconocidas para el extractor. Afirmar que la práctica demuestra Zero-shot sería un error conceptual. Para hablar de Zero-shot real se requeriría:

- Evaluar con identidades que no participaron en el entrenamiento del encoder.
- O bien, emplear un mecanismo adicional (atributos, texto, modelo generativo) que permita inferir la identidad a partir de información auxiliar.
- Documentar la separación estricta entre identidades de entrenamiento y de evaluación.

5.3 Limitaciones del experimento

- El dataset sintético es trivialmente separable; los resultados 1.0 no son extrapolables a datos reales.
- No se modelan variaciones de pose, iluminación, expresión, oclusión ni envejecimiento.

- El encoder es una CNN ligera; no se usan backbones preentrenados (ResNet50, FaceNet, MobileNetV2).
- No se aplica hard triplet mining, que suele ser necesario en datasets reales.
- No se calculan métricas ROC, EER ni curvas de calibración del umbral.

5.4 Extensión a imágenes reales autorizadas

El notebook incluye la función load_authorized_faces(root="/content/rostros") que permite sustituir el dataset sintético por fotografías reales, siempre que exista consentimiento explícito. En la ejecución validada, la carpeta /content/rostros no existía, por lo que la función retornó correctamente "Aún no existe /content/rostros". La estructura de carpetas requerida es:

/content/rostros/persona_01/foto1.jpg ... /content/rostros/persona_02/foto1.jpg ...

6. Conclusiones

- La red siamesa aprendió un espacio de embeddings discriminativo: las distancias positivas (0.1312) quedaron claramente separadas de las negativas (1.5421), con una relación de ≈ 11.75×.
- Triplet Loss con margen 0.8 fue efectiva para forzar la separación; la pérdida convergió de 0.3981 a ~0.0 en 18 épocas (prácticamente 0.0 desde la época 6).
- One-shot (1 referencia) y Few-shot (3 referencias + prototipo) alcanzaron accuracy 1.0 (44/44 y 36/36) en el dataset sintético, evidenciando la utilidad del aprendizaje métrico en escenarios de pocas referencias.
- El umbral pedagógico (0.8367) permitió verificar correctamente pares de la misma y distinta identidad (0.2070 → MISMA; 1.2789 → DIFERENTE), con un margen amplio respecto a las distancias medias observadas.
- La práctica NO demuestra Zero-shot real: las cuatro identidades evaluadas participaron en el entrenamiento del encoder. Este punto debe explicitarse en cualquier informe o presentación para no incurrir en afirmaciones incorrectas.
- Los resultados son válidos en el contexto sintético; en datos reales se esperaría una caída significativa de accuracy y la necesidad de preprocesamiento robusto, backbones preentrenados y hard triplet mining.

7. Anexos

7.1 Preguntas de cierre resueltas

¿Por qué una red basada en embeddings puede ser útil cuando aparecen identidades nuevas?

Porque una identidad nueva puede representarse mediante uno o pocos embeddings de referencia, sin redefinir una salida de clasificación ni reentrenar el modelo.

¿Qué diferencia existe entre detectar un rostro y verificar una identidad?

Detectar responde "¿hay un rostro y dónde está?"; verificar responde "¿estas dos representaciones corresponden a la misma identidad?".

¿Qué hace el margen en Triplet Loss?

Impone una separación adicional: la distancia Anchor-Negative debe quedar suficientemente más lejos que la Anchor-Positive (al menos el margen).

¿Por qué Few-shot puede ser más robusto que One-shot?

Porque combina varias referencias y reduce la dependencia de una sola captura particular (iluminación, pose, ruido).

¿Por qué no debemos afirmar Zero-shot real en este experimento?

Porque el encoder fue entrenado con las mismas cuatro identidades sintéticas que luego se evalúan; no son identidades realmente desconocidas para el extractor.

8. GitHub

Repositorio: https://github.com/BryanRoa/R2-A1-S10-Redes-Neuronales-V.git